

Series_de_tiempo_2


AMV

26/5/2020


Análisis de series de tiempo

Serie de tiempo estacionaria

```
gas = scan('http://verso.mat.uam.es/~joser.berrendero/datos/gas6677.dat')  
plot(gas)
```




```
#print(gas)  
  
gas.ts = ts(gas, start = c(1966,1), frequency = 12)  
  
# Estabilización de la varianza  
  
plot(log(gas.ts))
```




Eliminación de tendencia por diferenciación

```
x = log(gas.ts)
dif1.x = diff(x)
plot(dif1.x)
```




```
# Eliminación de la estacionalidad
```

```
dif12.dif1.x = diff(dif1.x, lag=12)  
plot(dif12.dif1.x)
```



```
# correlograma de la serie  
# representación gráfica de las autocorrelaciones  
#ro(k): las # correlaciones entre xt y xt+k, en función de k  
y = dif12.dif1.x  
acf(y)
```



Siempre se tiene que $\rho(0) = 1$. Las líneas discontinuas representan las bandas de confianza de $\rho(k)$ de nivel 95% bajo la hipótesis de que la serie es un ruido blanco (incorrelada).

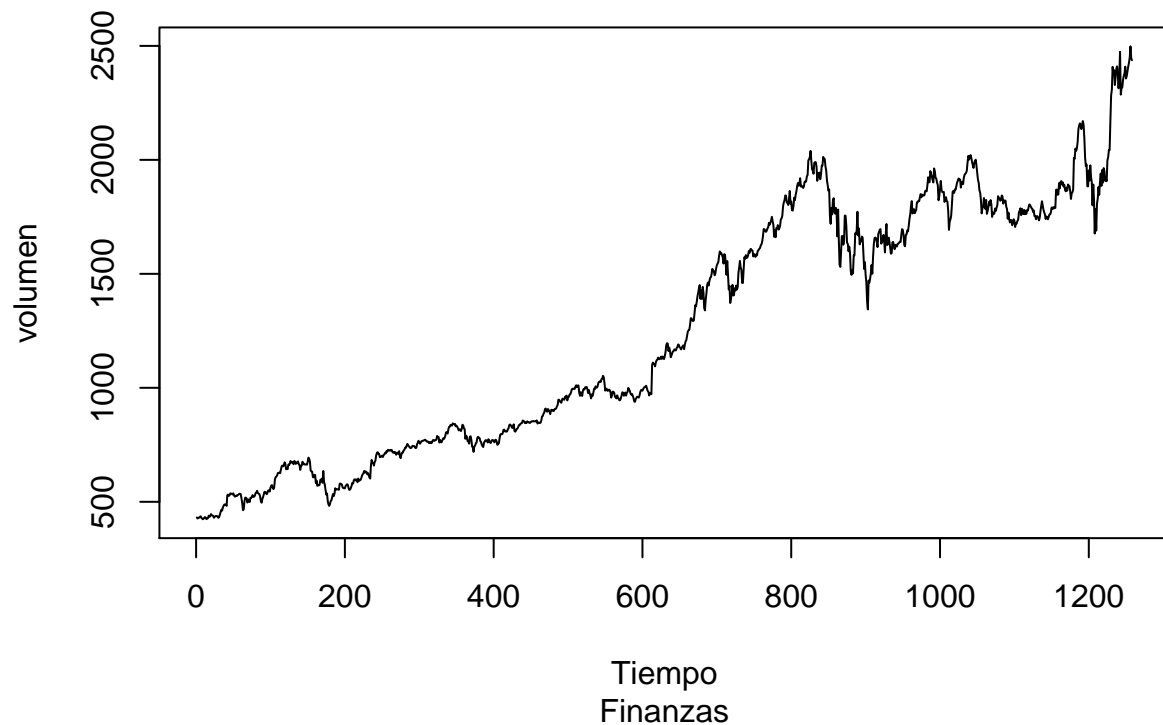
En el ejemplo las autocorrelaciones más significativas son las correlaciones entre la observación de un mes y la del mes siguiente, y la observación de un mes con la del mismo mes del año siguiente.

Serie de tiempo no estacionaria

1. El primer paso en la identificación del modelo es determinar si la serie es estacionaria, es decir, si la serie de tiempo parece variar alrededor de un nivel fijo.

La gráfica muestra un comportamiento creciente, indicando con esto la no presencia de estacionariedad.

```
AMZN1 <- read.csv("~/Clases UP/ESTADISTICA_MCD/AMZN1.csv", sep="")
amzn<-ts(AMZN1)
plot.ts(amzn, sub="Finanzas",xlab="Tiempo",ylab="volumen")
```




El siguiente paso en la identificación de un modelo tentativo es examinar las autocorrelaciones de muestra de datos.

El correlograma muestra un desvanecimiento lento de la función de autocorrelación indicando también no estacionariedad en la serie original.

En donde la función de autocorrelación. En el retardo k , es la autocorrelación entre los valores de las series que se encuentran a k intervalos de distancia.

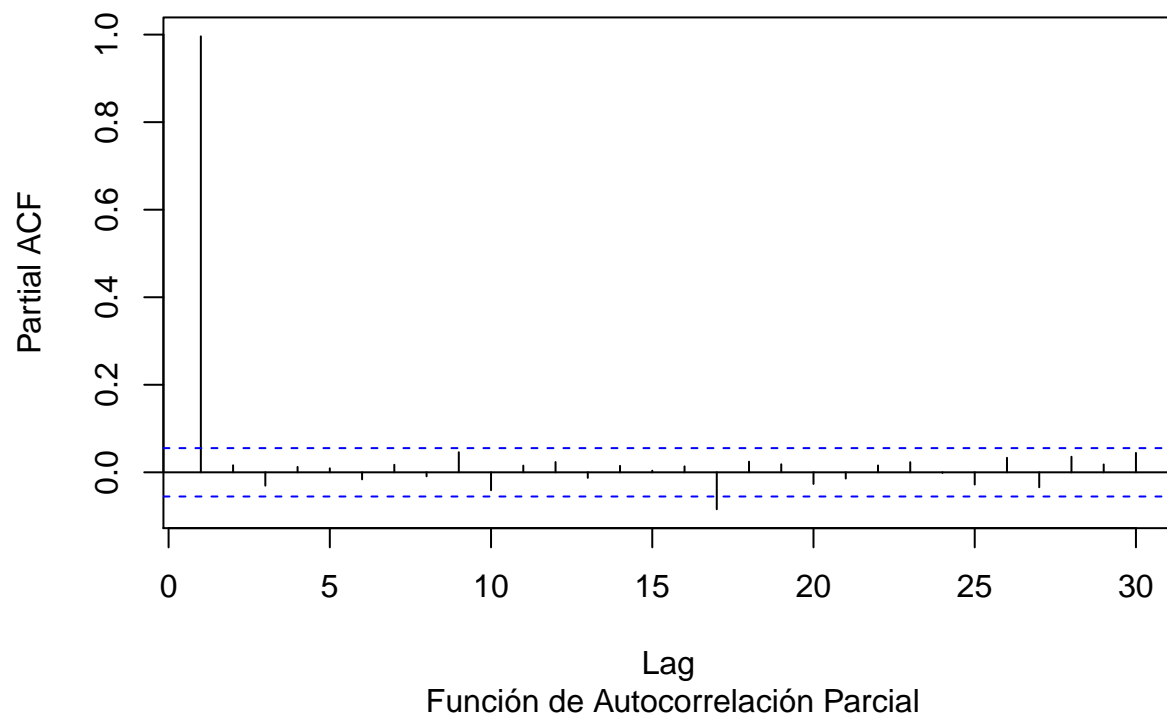
Función de autocorrelación parcial (FAP). En el retardo k , es la autocorrelación entre los valores de las series que se encuentran a k intervalos de distancia, teniendo en cuenta los valores de los intervalos intermedios.

```
acf(amzn,30,main="",sub="Función de Autocorrelación Simple")
```



Función de Autocorrelación Simple

```
pacf(amzn,30,main="",sub=" Función de Autocorrelación Parcial")
```



Confirmaremos lo dicho anteriormente con la prueba de Dickey - Fuller.

Ho: La serie es no estacionaria

H1: La serie es estacionaria

significancia $\alpha = 0.05$

```
library(fUnitRoots)
```

```
## Warning: package 'fUnitRoots' was built under R version 3.6.3
```

```
## Loading required package: timeDate
```

```
## Loading required package: timeSeries
```

```
## Warning: package 'timeSeries' was built under R version 3.6.3
```

```
## Loading required package: fBasics
```

```
## Warning: package 'fBasics' was built under R version 3.6.3
```

```
adfTest(amzn,lags=0,type=c("c"))
```

```
##
```

```
## Title:
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## Test Results:
```

```
## PARAMETER:
```

```
## Lag Order: 0
```

```
## STATISTIC:
```



```
##      Dickey-Fuller: -0.1423
##      P VALUE:
##      0.94
##
## Description:
## Tue May 26 17:26:37 2020 by user: anton
```

El valor de p mayor a 0.05 por lo que la hipótesis nula no se rechaza.

La serie no es estacionaria.

Si la serie no es estacionaria, se diferencia.

Al tomar las primeras diferencias observamos que la serie se estabiliza en torno a un valor medio.

El correlograma confirma un declinamiento rápido en el tiempo de la AFC y PAFC.


Prueba de Dickey-Fuller a la serie en Primera Diferencia:

1. Planteamiento de Hipótesis


Ho: La serie en primera diferencia es no estacionaria.

H1: La serie en primera diferencia es estacionaria.

```
plot.ts(diff(amzn),sub=" Serie en primera diferencia", xlab="Tiempo",ylab="Primera diferenciación")
```

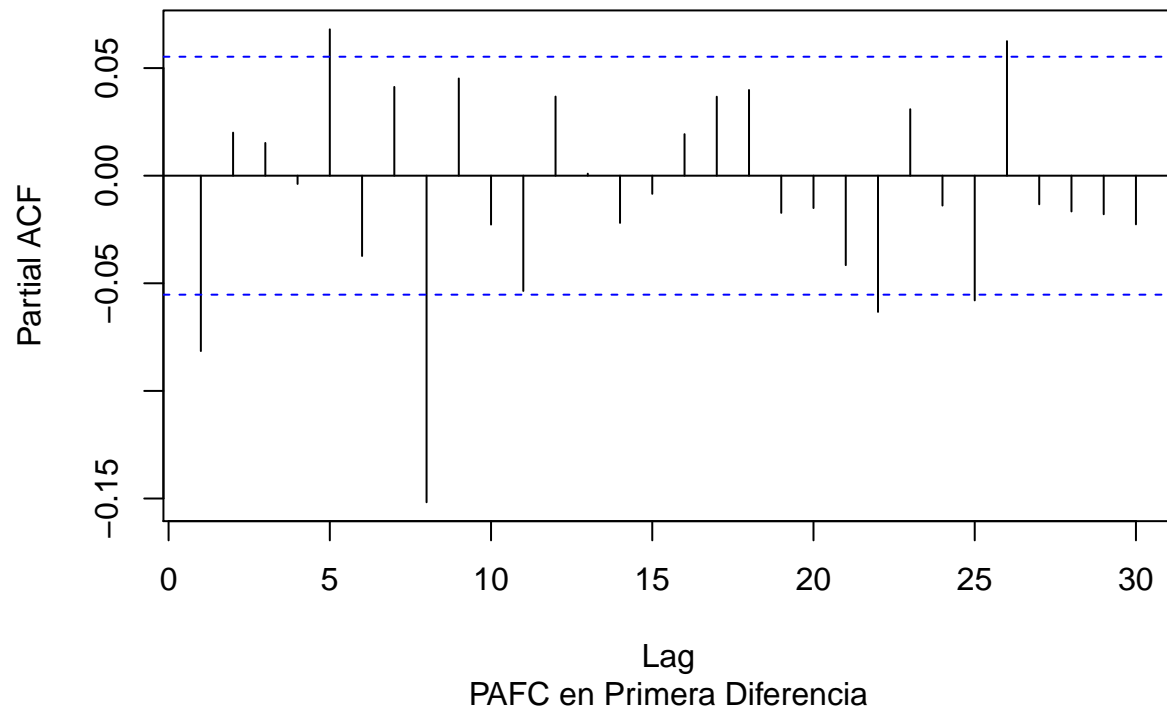


```
acf(diff(amzn),30,main="",sub="AFC en Primera Diferenciación")
```



Lag
AFC en Primera Diferenciación

```
pacf(diff(amzn),30,main="",sub="PAFC en Primera Diferencia")
```



```
adfTest(diff(amzn),lags=0,type=c("c"))
```

```
## Warning in adfTest(diff(amzn), lags = 0, type = c("c")): p-value smaller than
## printed p-value

##
## Title:
## Augmented Dickey-Fuller Test
##
## Test Results:
## PARAMETER:
## Lag Order: 0
## STATISTIC:
## Dickey-Fuller: -38.4237
## P VALUE:
## 0.01
##
## Description:
## Tue May 26 17:26:37 2020 by user: anton
```

El valor de p menor a 0.05 por lo que la hipótesis nula se rechaza.

Una vez que se ha obtenido una serie estacionaria, debemos identificar el modelo que se utilizará. El modelo se lleva a cabo comparando las autocorrelaciones y las autocorrelaciones parciales calculadas con los datos de la autocorrelaciones y las autocorrelaciones parciales teóricas de los diferentes modelos ARIMA.

Se evalúan los modelos asignando valores a los parámetros p,d,q.

Una vez que se han seleccionado los modelos tentativos, se deben estimar los parámetros para estos modelos.

```
arima1<-arima(diff(amzn),c(2,0,3))
```

```
## Warning in arima(diff(amzn), c(2, 0, 3)): possible convergence problem: optim  
## gave code = 1
```

```
arima1
```

```
##
```

```
## Call:
```

```
## arima(x = diff(amzn), order = c(2, 0, 3))
```

```
##
```

```
## Coefficients:
```

```
## Warning in sqrt(diag(x$var.coef)): Se han producido NaNs
```

```
##          ar1      ar2      ma1      ma2      ma3  intercept
```

```
##      -1.2934 -0.4784  1.2387  0.4449  0.0512      1.6299
```

```
## s.e.      NaN      NaN      NaN      NaN  0.0249      0.7345
```

```
##
```

```
## sigma^2 estimated as 696.6:  log likelihood = -5897.97,  aic = 11809.94
```

```
arima2<-arima(diff(amzn),c(0,1,1))
```

```
arima2
```

```
##
```

```
## Call:
```

```
## arima(x = diff(amzn), order = c(0, 1, 1))
```

```
##
```

```
## Coefficients:
```

```
##          ma1
```

```
##      -1.0000
```

```
## s.e.    0.0027
```

```
##
```

```
## sigma^2 estimated as 709.5:  log likelihood = -5908.27,  aic = 11820.54
```

```
#El criterio de información de Akaike (AIC)
```

```
#es una medida de la calidad relativa de un
```

```
#modelo estadístico, para un conjunto
```

```
#dado de datos. Proporciona un medio para la
```

```
#selección del modelo.
```

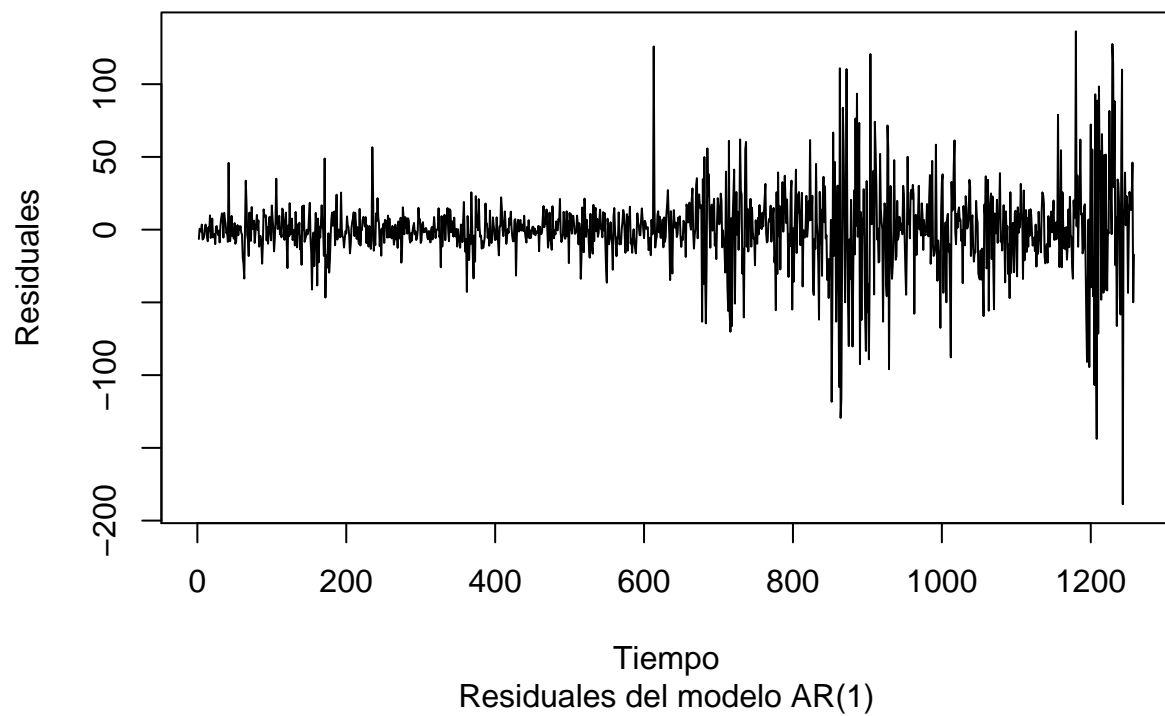
```
#AIC maneja un trade-off entre la bondad de ajuste
```

```
#del modelo y la complejidad del modelo.
```

```
#Se basa en la entropía de información: se ofrece una estimación relativa de la #información perdida cu
```


```
#determinado para representar el proceso #que genera los datos.
```

```
plot.ts(arima1$residuals,sub="Residuales del modelo AR(1)",xlab="Tiempo",ylab="Residuales")
```



```
acf(arima1$residuals, sub="Autocorrelaciones de los Residuales del modelo AR(1)", xlab="Tiempo", ylab="Au
```


Series arima1\$residuals



Autocorrelaciones de los Residuales del modelo AR(1)

```
qqnorm(arima1$residuals, sub="Gráfico Q para evaluar normalidad");qqline(arima1$residuals)
```

Normal Q-Q Plot



Theoretical Quantiles
Gráfico Q para evaluar normalidad

```
shapiro.test(arima1$residuals)
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  arima1$residuals  
## W = 0.8683, p-value < 2.2e-16
```

Los resultados son similares en cuanto al valor de AIC y σ^2 por lo que decidimos por el modelo ARIMA1.


Validación del Modelo

Estacionariedad de los residuales La siguiente figura muestra una posible estacionariedad entre los residuales del modelo. Esto lo confirmaremos con un correlograma.

El diagrama Q-Q de los residuos del modelo AR(1) estimado para la serie se muestra en la figura. Los puntos parecen seguir la línea recta bastante de cerca, aunque parece desviarse en el extremo superior. Este gráfico no nos llevaría a rechazar la normalidad de los términos de error en este modelo.


Además, la prueba de normalidad de Shapiro-Wilk aplicada a los residuos produce un estadístico de prueba de $W = 0.8683$, lo que corresponde a un valor de p de 2.2×10^{-16} , y no rechazaría la normalidad basado en esta prueba.

```
plot.ts(arima1$residuals,sub="Residuales del modelo ARIMA1", xlab="Tiempo",ylab="Residuales")
```



```
acf(arima1$residuals, sub="Autocorrelaciones de los Residuales del modelo ARIMA1", xlab="Tiempo", ylab="A
```



Series arima1\$residuals



Autocorrelaciones de los Residuales del modelo ARIMA1

```
pacf(arima1$residuals, sub="Autocorrelaciones Parciales de los Residuales del modelo AR(1)", xlab="Tiempo")
```

Series arima1\$residuals



Autocorrelaciones Parciales de los Residuales del modelo AR(1)

#Los correlogramas muestran que no existe autocorrelación significativa en los residuales.
`qqnorm(arima1$residuals, sub="Figura 09: Gráfico Q para evaluar normalidad");qqline(arima1$residuals)`




Figura 09: Gráfico Q para evaluar normalidad

```
shapiro.test(arima1$residuals)
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  arima1$residuals  
## W = 0.8683, p-value < 2.2e-16
```